



Sephora Product Review

Kelompok 10


Fajri Hadiid Abdani



- 1 Perkembangan industri e-commerce yang sangat pesat
- 2 Data produk yang tidak dimanfaatkan secara maksimal
- 3 Kurangnya experience user dari penggunaan website



Bagaimana cara meningkatkan kinerja perusahaan dengan memanfaatkan pendekatan machine learning sehingga dengan melakukan optimasi sehingga perusahaan dapat berjalan secara efektif dan efisien?



Klasifikasi

Klasifikasi sebuah produk direkomendasikan atau tidak kepada pengguna

Regresi

Memprediksi harga jual produk untuk product launching

Clustering

Melihat tingkat kepuasan pengguna agar bisa tersegmentasi



Meningkatkan pengalaman pengguna


Meningkatkan daya saing perusahaan



Sephora Products and Skincare Reviews



Dataset Sephora merupakan dataset yang berasal dari kaggle dengan metode pengambilan secara scrapping,pada tahun 2023.



8K Row

23 Feature

49K Row

19 Feature

Data

Feature & Data Type

```
class pandas.core.frame.DataFrame
RangeIndex: 49977 entries, 0 to 49976
Data columns (total 19 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Unnamed: 0                            49977 non-null  int64
1   author_id                             49977 non-null  object
2   rating                                49977 non-null  int64
3   is_recommended                        46160 non-null  float64
4   helpfulness                           36522 non-null  float64
5   total_feedback_count                  49977 non-null  int64
6   total_neg_feedback_count              49977 non-null  int64
7   total_pos_feedback_count              49977 non-null  int64
8   submission_time                       49977 non-null  object
9   review_text                           49918 non-null  object
10  review_title                           35599 non-null  object
11  skin_tone                             42776 non-null  object
12  eye_color                             43717 non-null  object
13  skin_type                             46346 non-null  object
14  hair_color                            41126 non-null  object
15  product_id                            49977 non-null  object
16  product_name                          49977 non-null  object
17  brand_name                            49977 non-null  object
18  price_usd                             49977 non-null  float64
dtypes: float64(3), int64(5), object(11)
memory usage: 7.2+ MB
```

Missing value,Duplicated

Unnamed: 0	0
author_id	0
rating	0
is_recommended	3817
helpfulness	13455
total_feedback_count	0
total_neg_feedback_count	0
total_pos_feedback_count	0
submission_time	0
review_text	59
review_title	14378
skin_tone	7201
eye_color	6260
skin_type	3631
hair_color	8851
product_id	0
product_name	0
brand_name	0
price_usd	0

```
df.duplicated().sum()
np.int64(0)
```


Data Imputation

Mean

Mode


0

WHAT




Feature **rating** memiliki nilai lebih yang menjelaskan dari sebuah produk **direkomendasikan** atau tidak dan pada gambar dapat **terlihat jelas pemisahan** antara dua kelas yang berbeda terhadap rating,serta juga untuk **total feedback count** justru berbanding terbalik yang mana ini distribusinya seperti overlapiing sehingga tidak terlihat jelas bahwa ini bisa mendeskripsikan feature rekomendasi dengan sangat jelas karena **variansi yang besar**

WHY



Berdasarkan **probabilitas yang ada dari rating dan rekomendasi memiliki hubungan yang berbanding lurus** dengan rekomendasi sehingga dengan ini keduanya memiliki korelasi yang kuat ini dapat dilihat bahwa **produk dengan rating lebih tinggi secara kuantitas lebih banyak direkomendasikan**,hal ini menjadi penting untuk diidentifikasi karena ini dapat digunakan untuk menilai kualitas produk sepanjang tahun

HOW



Berdasarkan data korelasi diatas sebuah **produk dapat dikatakan “menolong”** pengguna **tidak berdasarkan total dari jumlah feedback** yang diberikan **tetapi lebih terfokus kepada jenis dari kualitas komentar/ulasan** yang dihasilkan positive atau negatif dapat dilihat **distribusi positive feedback tersebar banyak** dibandingkan negative feedback namun **tetap saja tidak berpengaruh signifikan**



Classification

Decision Tree Classifier

=== Decision Tree ===
Akurasi: 0.9569168157737782

	precision	recall	f1-score	support
0.0	0.96	0.96	0.96	14550
1.0	0.96	0.96	0.96	13953
accuracy			0.96	28503
macro avg	0.96	0.96	0.96	28503
weighted avg	0.96	0.96	0.96	28503

XGBoost Clasifier

=== XGBoost ===
Akurasi: 0.9715117706908045

	precision	recall	f1-score	support
0.0	0.97	0.97	0.97	14550
1.0	0.97	0.97	0.97	13953
accuracy			0.97	28503
macro avg	0.97	0.97	0.97	28503
weighted avg	0.97	0.97	0.97	28503

Regression

Lasso Regression
Random Fores

PERBANDINGAN HASIL MODEL

LASSO REGRESSION -> R²: 0.672 | MSE: 1795.072 | RMSE: 42.368
RANDOM FOREST -> R²: 0.967 | MSE: 178.693 | RMSE: 13.368

Clustering

DBSCAN

dbscan_cluster	rating mean	is_recommended mean	helpfulness mean	total_feedback_count mean	\
-1	3.514592	0.629389	0.576954	15.788418	
0	5.000000	1.000000	0.000000	0.220000	
1	5.000000	1.000000	0.954932	5.485714	
2	5.000000	1.000000	0.864654	5.804598	
3	5.000000	1.000000	0.588844	3.892256	
...	...	...	...	...	
526	1.000000	0.000000	0.842857	5.300000	
527	2.000000	0.000000	0.864881	4.200000	
528	4.000000	1.000000	0.975000	2.100000	
529	1.000000	0.000000	0.723560	10.000000	
530	5.000000	1.000000	0.533929	3.375000	

dbscan_cluster	total_neg_feedback_count mean	total_pos_feedback_count mean	price_usd mean	
-1	4.243388	11.545030	90.763630	
0	0.220000	0.000000	63.470000	
1	0.400000	5.085714	53.157048	
2	0.804598	5.000000	51.988391	
3	0.589226	3.303030	49.595926	
...	...	...	...	
526	0.900000	4.400000	29.300000	
527	0.800000	3.400000	29.300000	
528	0.100000	2.000000	36.699000	
529	2.700000	7.300000	40.500000	
530	1.500000	1.875000	42.000000	

K-Means

kmeans_cluster	rating mean	is_recommended mean	helpfulness mean	total_feedback_count mean	\
0	4.717727	0.998944	0.033669	0.966967	
1	1.902491	0.045141	0.606888	16.356460	
2	4.720918	0.999518	0.885754	10.156926	

kmeans_cluster	total_neg_feedback_count mean	total_pos_feedback_count mean	price_usd mean	
0	0.772493	0.194474	73.721613	
1	5.449188	10.907272	64.371105	
2	1.420974	8.735951	63.367521	



A photograph of a Sephora store interior, viewed through a glass entrance. The store is brightly lit with track lighting. Shelves and displays are filled with various cosmetic products. In the foreground, a sign on the left reads "oh snap! 50% OFF". A display in the center features NARS products and a sign that says "Foundations to know". Another display on the right shows "WHAT'S HAPPENING" magazine. Two people are visible inside the store: one in the background looking at a product, and another in the foreground on the right looking at a display. The store has a modern, clean aesthetic with white walls and a tiled floor. The entire image is overlaid with a semi-transparent red filter.

THANK YOU